

7 - Datenjournalismus, Hausaufgabe und Abschluss

author: Benedict Witzenberger date: 18. April 2019 autosize: true

Was wir jetzt noch vorhaben

Kleiner Ausblick auf Datenvisualisierung mit R

Ein bisschen was zum Datenjournalistenworkflow

Wir sprechen über das Kursprojekt

Und es gibt eine kleine Hausaufgabe (juchu!)

Datenvisualisierung mit R

Dazu gibt es einen ganzen Blockkurs (Teil IV)

Deswegen nur eine kleine Einführung:

R kann in zahlreichen Formaten Grafiken ausgeben: PNG, JPEG, PDF, SVG, ...

R kann praktisch alle Grafikformen darstellen, komplizierte Formen müssen handschriftlich programmiert werden.

Es gibt zwei Hauptbibliotheken für Grafiken: Base und ggplot2

ggplot2

Entwickelt seit 2005 von Hadley Wickham

basiert auf Leland Wilkinsons "Grammar of Graphics" - das heißt: Grafiken werden in Einzelteile zerlegt und dargestellt.

das heißt für uns: Wir können die Grafiken sehr einfach umkonfigurieren

eines der beliebtesten R-Packages

aktuelle Version 3.1.1

Der Einstieg ist relativ einfach, aber die Möglichkeiten muss man sich aufwendiger erschließen

Base

Standard-Grafikbibliothek in R, vorinstalliert.

Geht sehr einfach und schnell

Reicht für kleine Analysen

```
attach(mtcars)
plot(wt, mpg)
abline(lm(mpg~wt))
title("Regression von MPG auf Weight")
```

Scatterplot

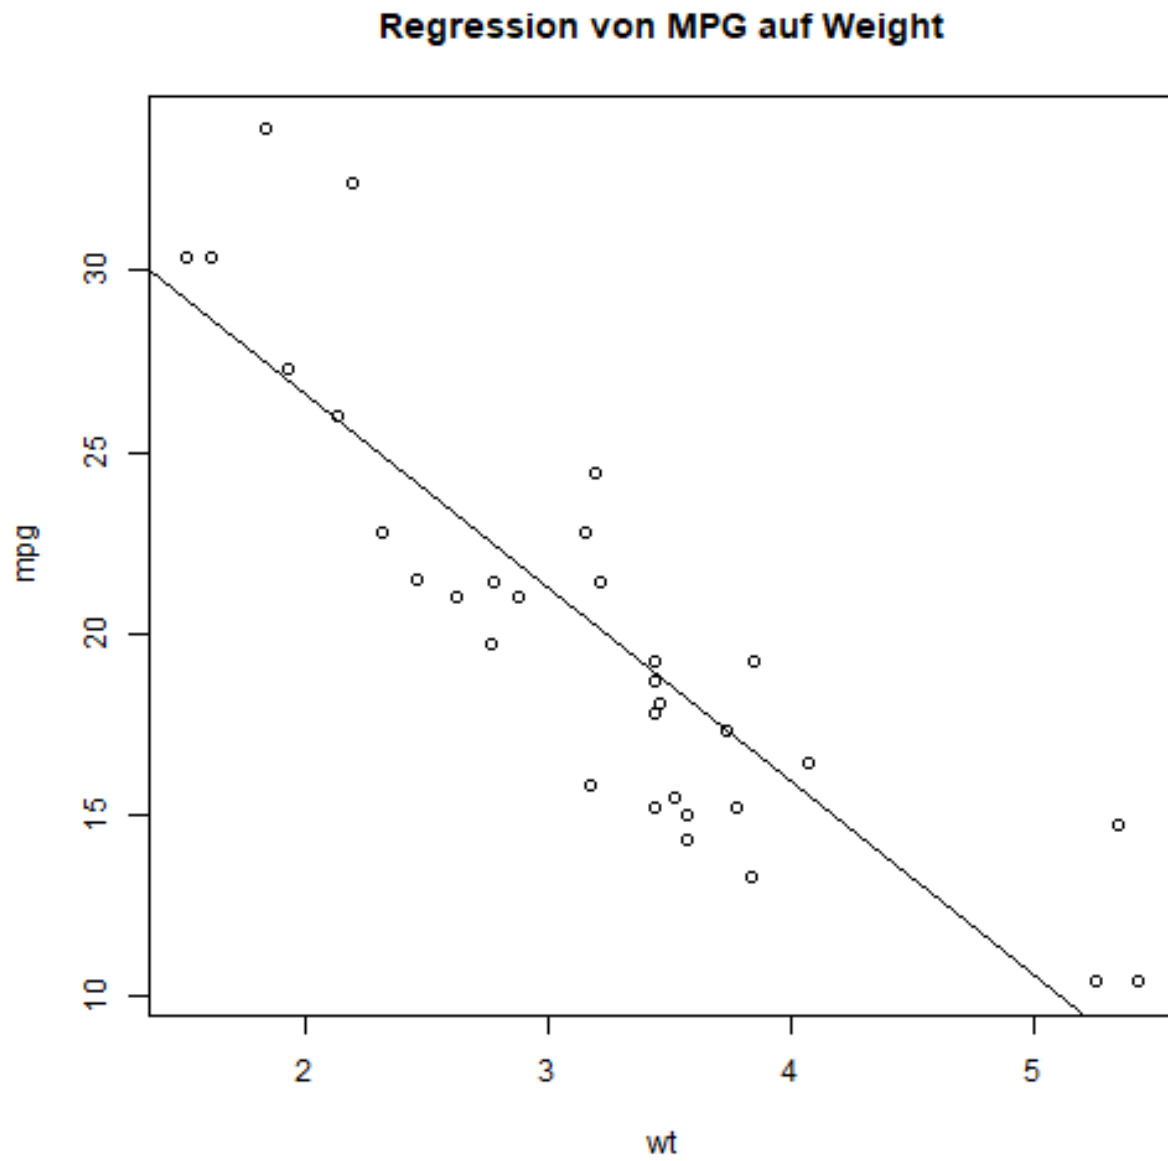


Figure 1: plot of chunk unnamed-chunk-1

```
vector <- c(1, 3, 6, 4, 9)

plot(vector)
```

Weitere Einstellungsmöglichkeiten in `plot()`:

```
main = Titel
xlab/ylab = X-Achsenbeschriftung
pch = Form der Punkte:
col = Farbe
font = Schriftart
cex = Schriftgrößen (in diversen Abstufungen, wie cex.main, cex.sub, cex.lab)
frame = TRUE/FALSE für Rahmen
```

Liniendiagramm

```
x<-1:10; y1=x*x; y2=2*y1

plot(x, y1, type="b", pch=19, col="red", xlab="x", ylab="y")

lines(x, y2, pch=18, col="blue", type="b", lty=2)

legend("topleft", legend=c("Line 1", "Line 2"),
      col=c("red", "blue"), lty=1:2, cex=0.8)
```

Wichtig: `lines()` alleine zeichnet keinen Graph, vorher muss `plot()` aufgerufen werden.

```
type = welcher Plot-Typ gezeichnet werden soll ("p" für "points", "l" für "lines", "b" für "both")
lty = Linientyp
legend() fügt eine Legende hinzu
```

Säulendiagramm

Nutzen wir das Dataset `VADeaths` (Todesrate pro 1000 in Virginia in 1940, Altersgruppen ab 50 Jahren):

```
x <- VADeaths[1:5, "Urban Male"]

barplot(x)

barplot(x, horiz = TRUE)
```

```
names.arg = Namen der Gruppen ändern
border = Farbe der Ränder (einzeln, oder als Vektor)
beside = TRUE/FALSE für gruppierte Säulen/Balken
```




Figure 2: plot of chunk unnamed-chunk-2



Figure 3:




Figure 4: plot of chunk unnamed-chunk-3




Figure 5: plot of chunk unnamed-chunk-4




Figure 6: plot of chunk unnamed-chunk-4

legend = rownames(VADeaths) würde das Diagramm stapeln.

Histogramm

```
x <- c(rnorm(200, mean=55, sd=5), rnorm(200, mean=65, sd=5))  
  
hist(x)
```

Abwandlung: Densityplot

```
dens <- density(x)  
plot(dens, frame = FALSE, col = "steelblue")
```

breaks = legt die Zahl der Bruchpunkte fest (oder den Algorithmus, der sie berechnet - z.B. Struges (default) Scott oder Freedman-Diaconis)

polygon(dens, col = "steelblue") würde den Density-Plot mit Farbe füllen

Graph als Bild speichern

In RStudio:

Im R-Code:

- Vor dem plot(): jpeg(), png(), svg() oder pdf() mit entsprechendem Dateinamen und (falls gewünscht) Größenangaben (width, height)
- plot() erstellen
- dev.off()

```
jpeg("grafik.jpg", width = 1024, height = 768, units = "px")  
plot(x, y, main = "Das ist der Titel")  
dev.off()
```

Datenjournalismus: Zwei Herangehensweisen

Von den Daten her

Wir haben Daten und suchen darin nach einer Geschichte:

- Minimum/Maximum
 - Ausreißer
 - NAs, wo keine sein sollten; Daten, wo keine sein sollten
 - Durchschnitt
 - Häufungen
 - Wandel, Trends
 - Muster aufzeigen
-




Figure 7: plot of chunk unnamed-chunk-5




Figure 8: plot of chunk unnamed-chunk-6

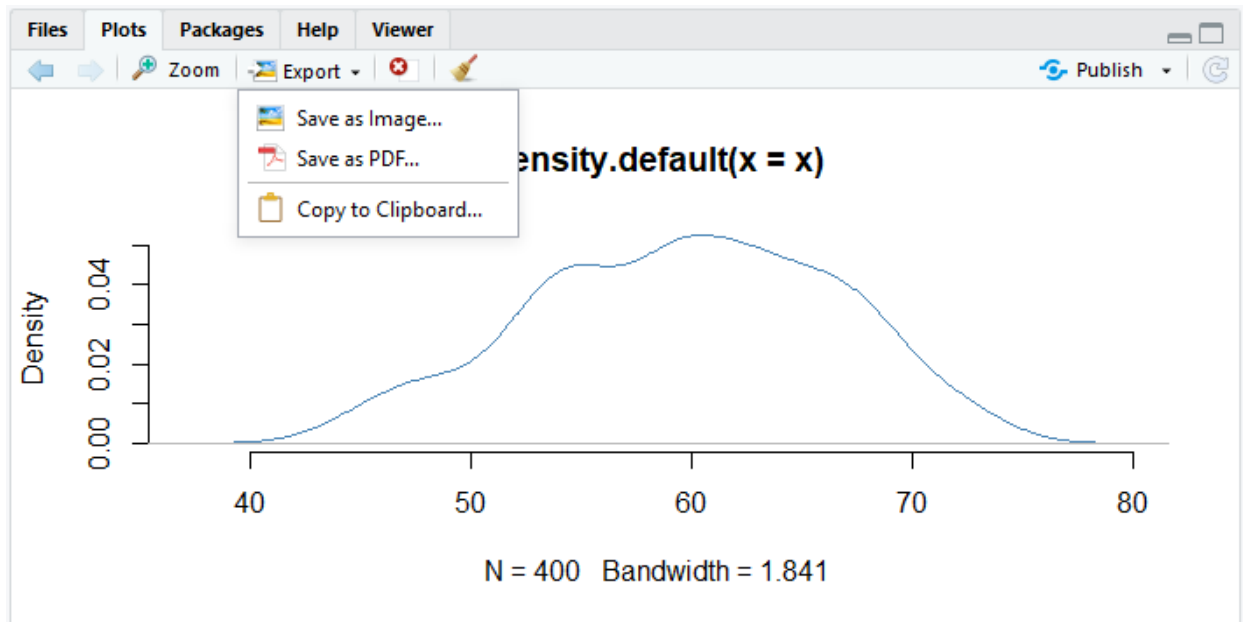


Figure 9:

Von der These her

Lassen sich Daten finden, die These best tigen k nnen?


- These operationalisieren
- Datenbanken durchsuchen
- Forscher kontaktieren
- eigene Variablen messen
- eigene Berechnungen durchf hren
- <- auch die Fragen von links helfen

Ist Datenjournalismus wirklich nötig?

1. The report needs to become more visual.

The Times has an unparalleled reputation for excellence in visual journalism. We have defined multimedia storytelling for the news industry and established ourselves as the clear leader. Yet despite our excellence, not enough of our report uses digital storytelling tools that allow for richer and more engaging journalism. Too much of our daily report remains dominated by long strings of text.

Share of stories with deliberately placed visual elements



Quelle: New York Times 2020 Report

Was ist Datenjournalismus?

“important, focused information that is useful to people’s lives and helps them understand the world” *Adrian Holovaty 2006*

Daten + Frage + Analytisches Vorgehen = Datenjournalismus

Wer macht Datenjournalismus?

- Sozialwissenschaftler
- Entwickler
- Kartographen
- Statistiker
- Mathematiker
- bislang wenige “studierte” Datenjournalisten (aber es gibt inzwischen einige Studiengänge: Dortmund, Leipzig)

Welche Skills braucht es?

- Data Literacy
- Programmieren/Coden (oder: Tools kennen?)
- Designen
- Schreiben
- Recherchieren
- Transparenz

Wie funktioniert Datenjournalismus

Daten recherchieren

-> Daten bereinigen

-> Daten analysieren [Aufgabe der Datenjournalisten, nur manchmal mit Entwicklern]

-> Daten visualisieren [Designer und Entwickler]

Datenjournalismus bei der SZ

“Daten-Team” der Entwicklungsredaktion (neben Video, Podcast, Storytelling):

- 3 DatenjournalistInnen von SZ.de
- ein SZ.de-Datenvolontär
- 2 Datenjournalisten von der Zeitung
- 1-2 Entwickler
- 1 Designer

Technik: R, Python, QGIS, Spark, Javascript, SQL, HTML, CSS, Google Docs, Adobe Illustrator

Projektdauer: kurz-, mittel- und langfristige Projekte. Tendenz: mittel- und langfristig

Ziel: Visuellen Journalismus bei der SZ fördern, ansprechbar sein für “programmierte Recherche”, Knowhow im Bereich AI/KI und Datenschutz




Figure 10:

Zwei Beispiele für SZ-Datenstücke

Ein Jahr Trump

Liga der Langeweile

Wo kommen die Daten her?

Früher vor allem bestehende Datenbanken:

- DeStatis
- data.un.org
- www.who.int/gho/database/en/

Heute eher:

- Twitter
- OpenStreetMap

Theoretisch: Alles, was scrapebar ist

Was ändert sich?

- Open Source und Open Data wird immer mehr (in Deutschland nur sehr zurückhaltend)
- Informationsfreiheitsgesetze in Deutschland (und den meisten Ländern, immer noch drei Bundesländer ohne entsprechende Gesetze: Bayern, Niedersachsen, Sachsen)
- sehr gut vernetzte Datenjournalistenszene
- Programmieren lernen wird immer einfacher (Codecademy etc.)

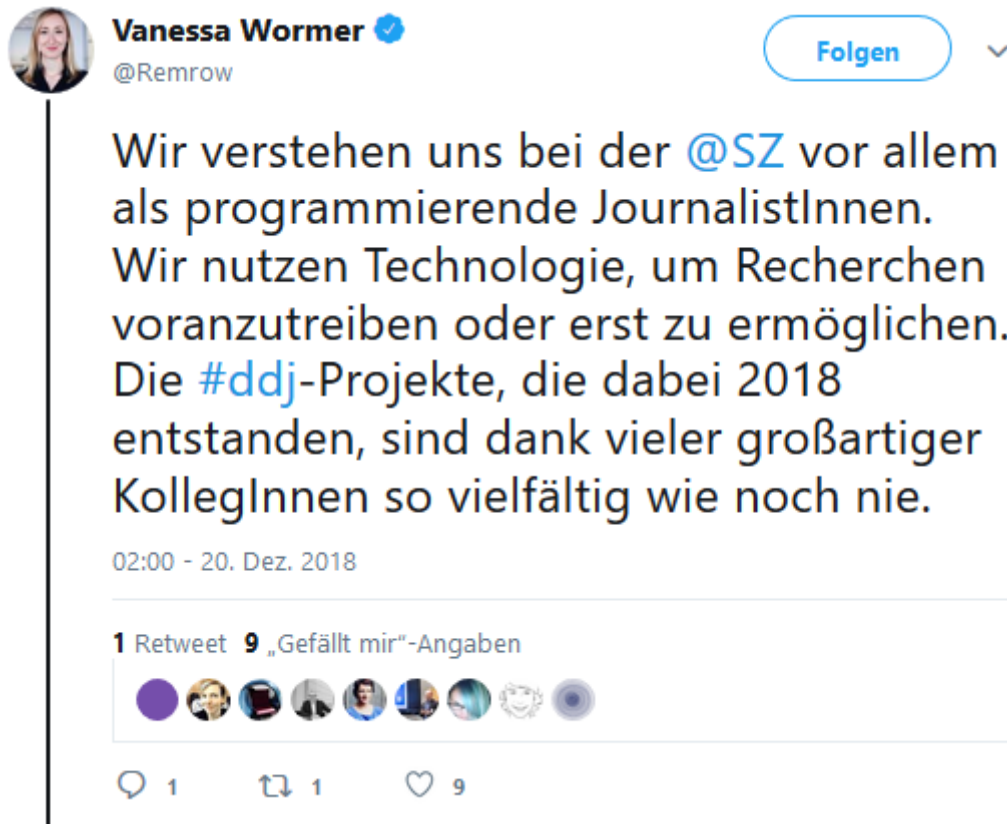


Figure 11:

- viele kostenlose oder billige Tools (Datawrapper, CartoDB, QGIS)

Kritik: Stagnation im Datenjournalismus

“Allerdings meine ich, eine Stagnation zu beobachten: Lebte das Genre in den ersten Jahren vom Reiz des Neuen, das Dank aufsehenserregender Visualisierungen hervorstach, sind die Formate nun weitgehend ausgereizt. [...] Doch der Drang zum Leuchtturm-Projekt (oder Liebhaber-Projekt einzelner Redakteure) herrscht weiter vor. Ich persönlich finde das mittlerweile recht ermüdend, weil eben keine Weiterentwicklung zu erkennen ist: Weder thematisch noch konzeptionell. Im Gegenteil: Die Themensetzung wirkt oft wahllos oder gar willkürlich.”

Lorenz Matzat Ende 2018 auf seinem Blog

Antwort der SZ-Daten-Teamleiterin:

Quelle zum Tweet

Mehr dazu: Gespräch in “Was mit Medien” (Dlf Nova)

Wie geht's jetzt weiter?

Vorschlag: Wir entwickeln alleine oder in Kleingruppen datenjournalistische Projekte, die am Ende des R-Bootcamps fertig sein sollen.

Fragen:

Was passt zu euch / zu eurer Redaktion?

Habt ihr Ideen oder Thesen?

Wo könntet ihr anfangen zu suchen?

Next Steps:

Daten organisieren/researchieren

Wir sprechen uns am *20. Mai um 20.15 Uhr* per Videocall, bis dahin sollte die These stehen.

Bei Fragen könnt ihr jederzeit in Slack (ddj19) schreiben, oder mir eine Mail schicken: b.witzenberger@gmail.com

Hausaufgabe

Im Github habe ich eine Aufgabe vorbereitet, die euer Wissen aus diesem Seminar testen soll.

Abschluss Block 1

Abschlussrunde:

- Was ist bei euch besonders hängen geblieben?
- Was hätten ihr gerne mehr gemacht? / was weniger?
- Habt ihr das Gefühl, ihr habt alles verstanden?